

CLASIFICACIÓN DE IMÁGENES DE MAMOGRAFÍA

FERNANDO BARAJAS RAMÍREZ

LEOBARDO GARCÍA REYES


DAVID EDUARDO GALLARDO

INTRODUCCIÓN

Con el poder de computacional y la cantidad de datos que tenemos disponible hoy en día y que podemos generar es posible clasificar imágenes y detectar objetos en esas imágenes. Las redes neuronales convolucionales (CNN) permiten entrenar modelos que pueden identificar patrones en las imágenes que para los seres humanos sería más difícil. Los usos son muchos y uno de ellos es el de la detección del cáncer de mama que, aunque todavía no es perfecto, parece ser muy prometedor y una herramienta muy útil para los médicos.

Entre las ventajas podemos mencionar una mayor exactitud a la hora de detectar la presencia de tumores y si estos son malignos o benignos, realización de biopsias solo cuando sea realmente necesario y evitar la preocupación y el desgaste emocional a la paciente y a sus familiares debido a los falsos positivos.

PROBLEMA PROPUESTO






A partir de imágenes correspondientes a exámenes de mamografía, se busca determinar mediante la aplicación de un modelo de redes neuronales convolucionales (CNN) si una imagen corresponde a una paciente con un tumor maligno, benigno o en otro caso, en estado de salud normal.

Mediante este proyecto, se busca obtener un punto de referencia de las predicciones realizadas con un modelo respecto a la clasificación original, en este caso de un profesional de la salud

CONJUNTO DE DATOS

El conjunto de datos utilizado lleva por nombre The Complete Mini-DDSM, y fue obtenido del sitio Kaggle. Los datos se obtienen en 1952 carpetas (una por paciente), las cuáles contienen:

- 2 imágenes del estudio desde la perspectiva MLO (Medio lateral oblicua / Visto desde los lados)
- 2 imágenes del estudio desde la perspectiva CC (Craneocaudal / Visto desde arriba)
- Archivos con la máscara del área sospechada como tumor
- Información del paciente



DIVISIÓN DEL CONJUNTO DE DATOS:

Hay un total de 7,809 imágenes divididos en 3 clases: **Normal** (cuando no hay nada), **Benigno** (cuando hay un tumor benigno) y **Cáncer** (cuando hay un tumor maligno).

Conjunto de entrenamiento

5,464 imágenes de
mamografías dividido
en
Normal: 1,685,
Benigno: 1,878 y
Cáncer: 1,901.

Conjunto de validación

1,560 imágenes de
mamografías dividido
en
Normal: 481,
Benigno: 536 y
Cáncer: 543.

Conjunto de prueba

785 imágenes de
mamografías dividido
en
Normal: 242,
Benigno: 270 y
Cáncer: 273.

METODOLOGÍA



PREPROCESAMIENTO:

- Redimensionamiento de las imágenes.
- Normalización.
- Cambio aleatorio de las imágenes.

DEFINICIÓN DEL MODELO:

- Definir arquitectura del modelo CNN
- Entrenamiento del modelo

VALIDACIÓN DEL MODELO:

Validación del modelo con el conjunto de validación.

PRE-PROCESAMIENTO Y PREPARACIÓN DE LOS DATOS

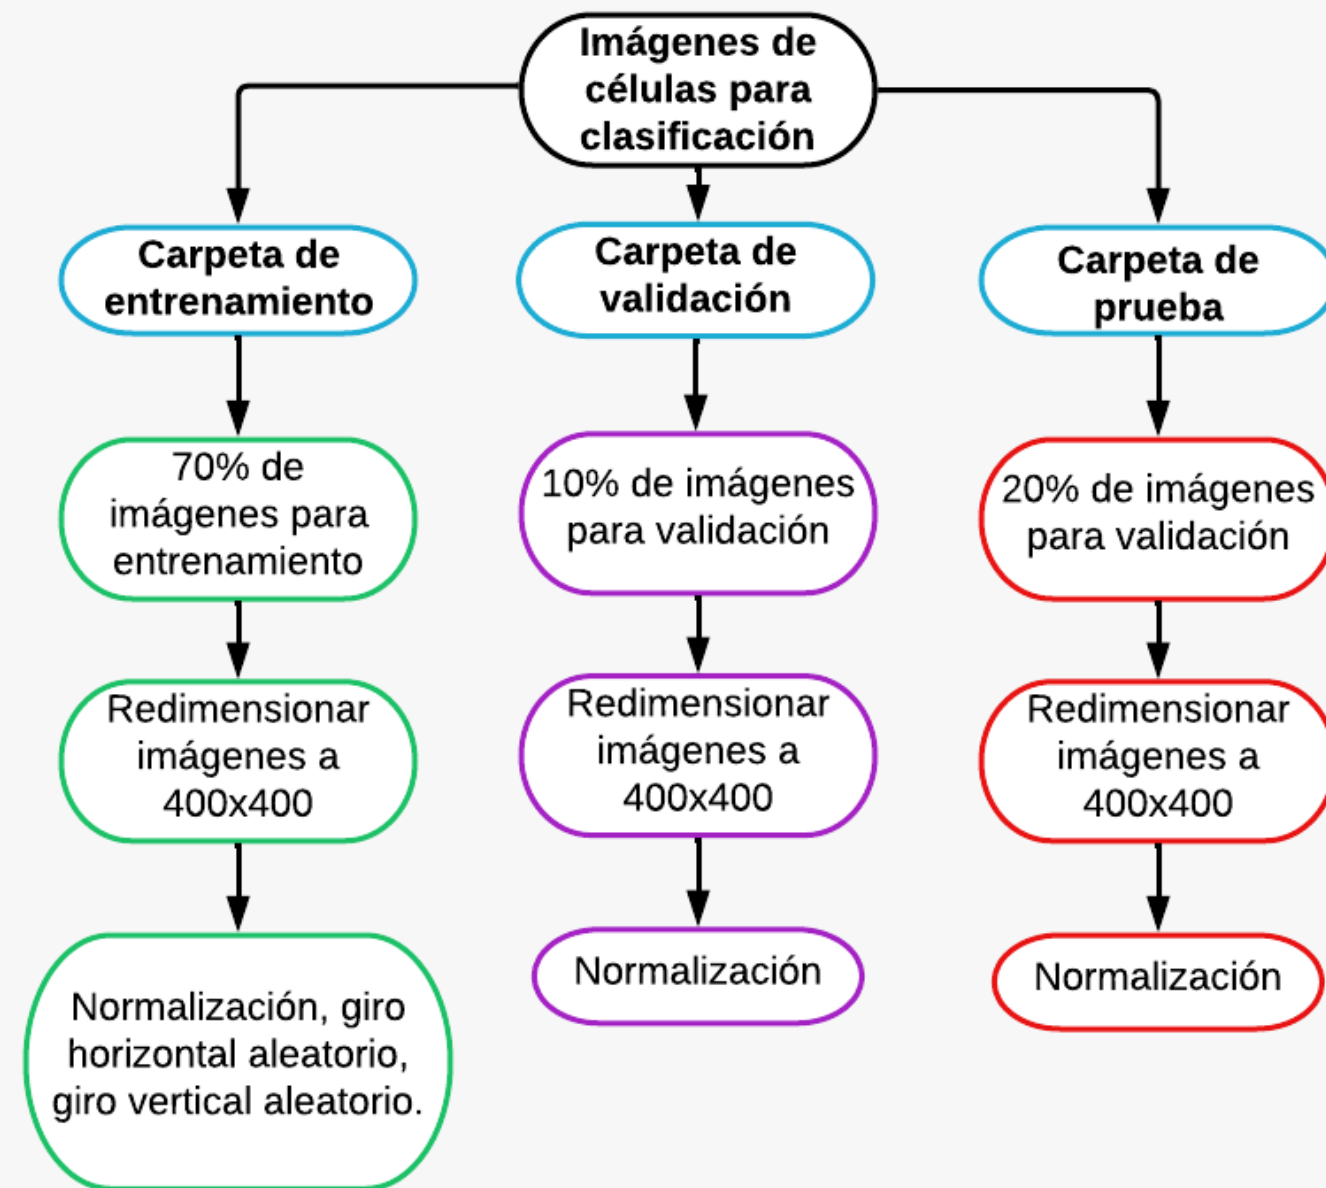




Imagen original



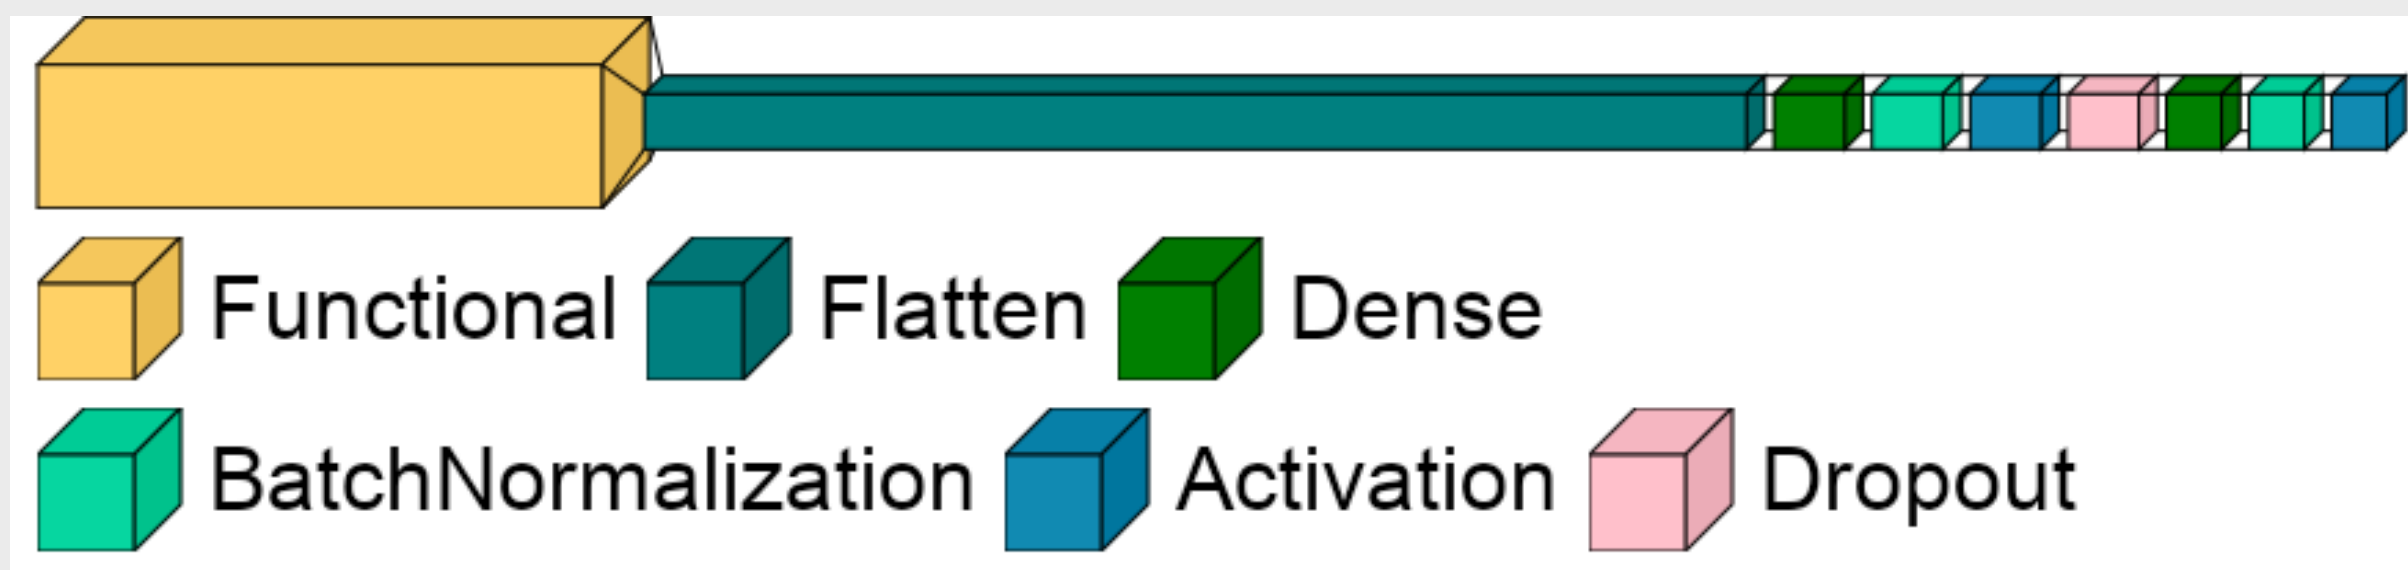
Nueva imagen cambiada




ARQUITECTURA DEL MODELO

Se utilizarón diferentes arquitecturas como Xception, DenseNet169, ResNet50V2, InceptionResNetV2 y EfficientNetB5.

Al final se optó por la arquitectura Xception por mejores resultados, añadiendole unas capas extras.



ARQUITECTURA DEL MODELO XCEPTION




MEJORAMIENTO DEL MODELO

Para obtener mejores resultados, dependiendo el tipo de arquitectura se:

- Agregaba o quitaba capas de neuronas.
- Capa de Dropout para evitar sobre ajuste y que de una mejor generalización.
- Una función para reducir la tasa de aprendizaje cuando una métrica ha dejado de mejorar.
- Una función para dejar de entrenar el modelo cuando una métrica monitoreada haya dejado de mejorar.
- Pesos pre-entrenados por "Imaginet" o iniciados aleatoriamente.
- Diferentes redimensiones de imágenes.


RESULTADOS

Gráfico de exactitud



Entrenamiento: 94.20%
Validación: 81.15%

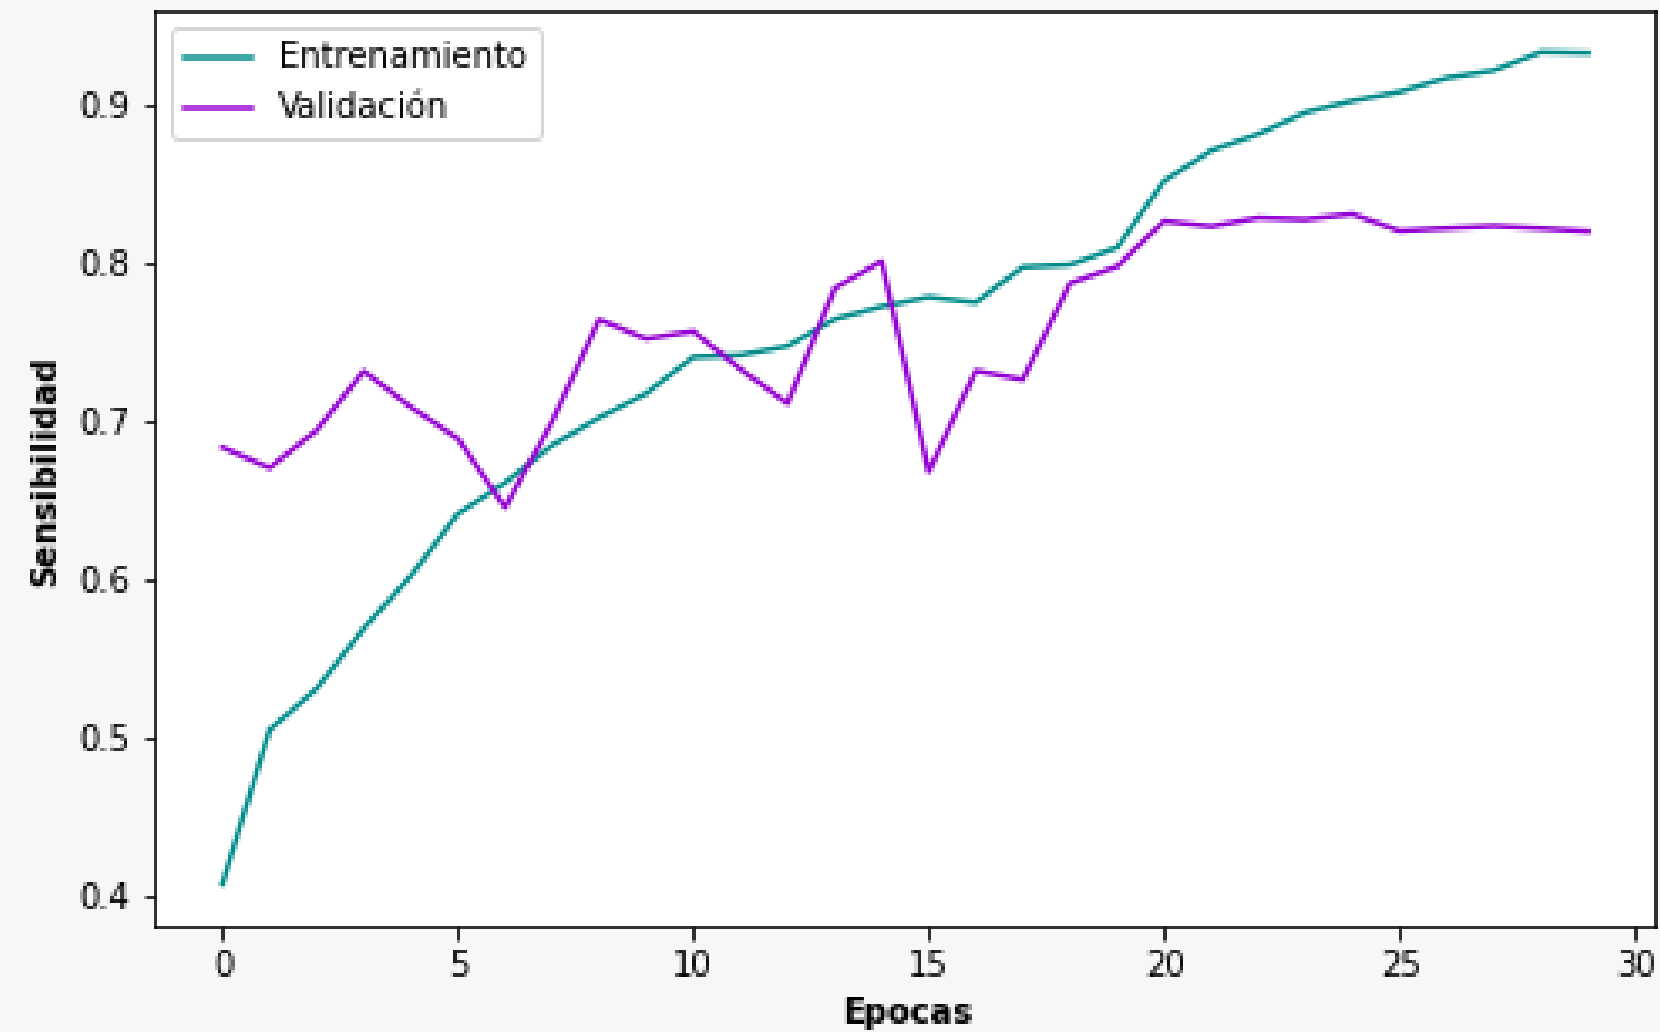
Gráfico de precisión



Entrenamiento: 94.67%
Validación: 82.02%


RESULTADOS

Gráfico de sensibilidad



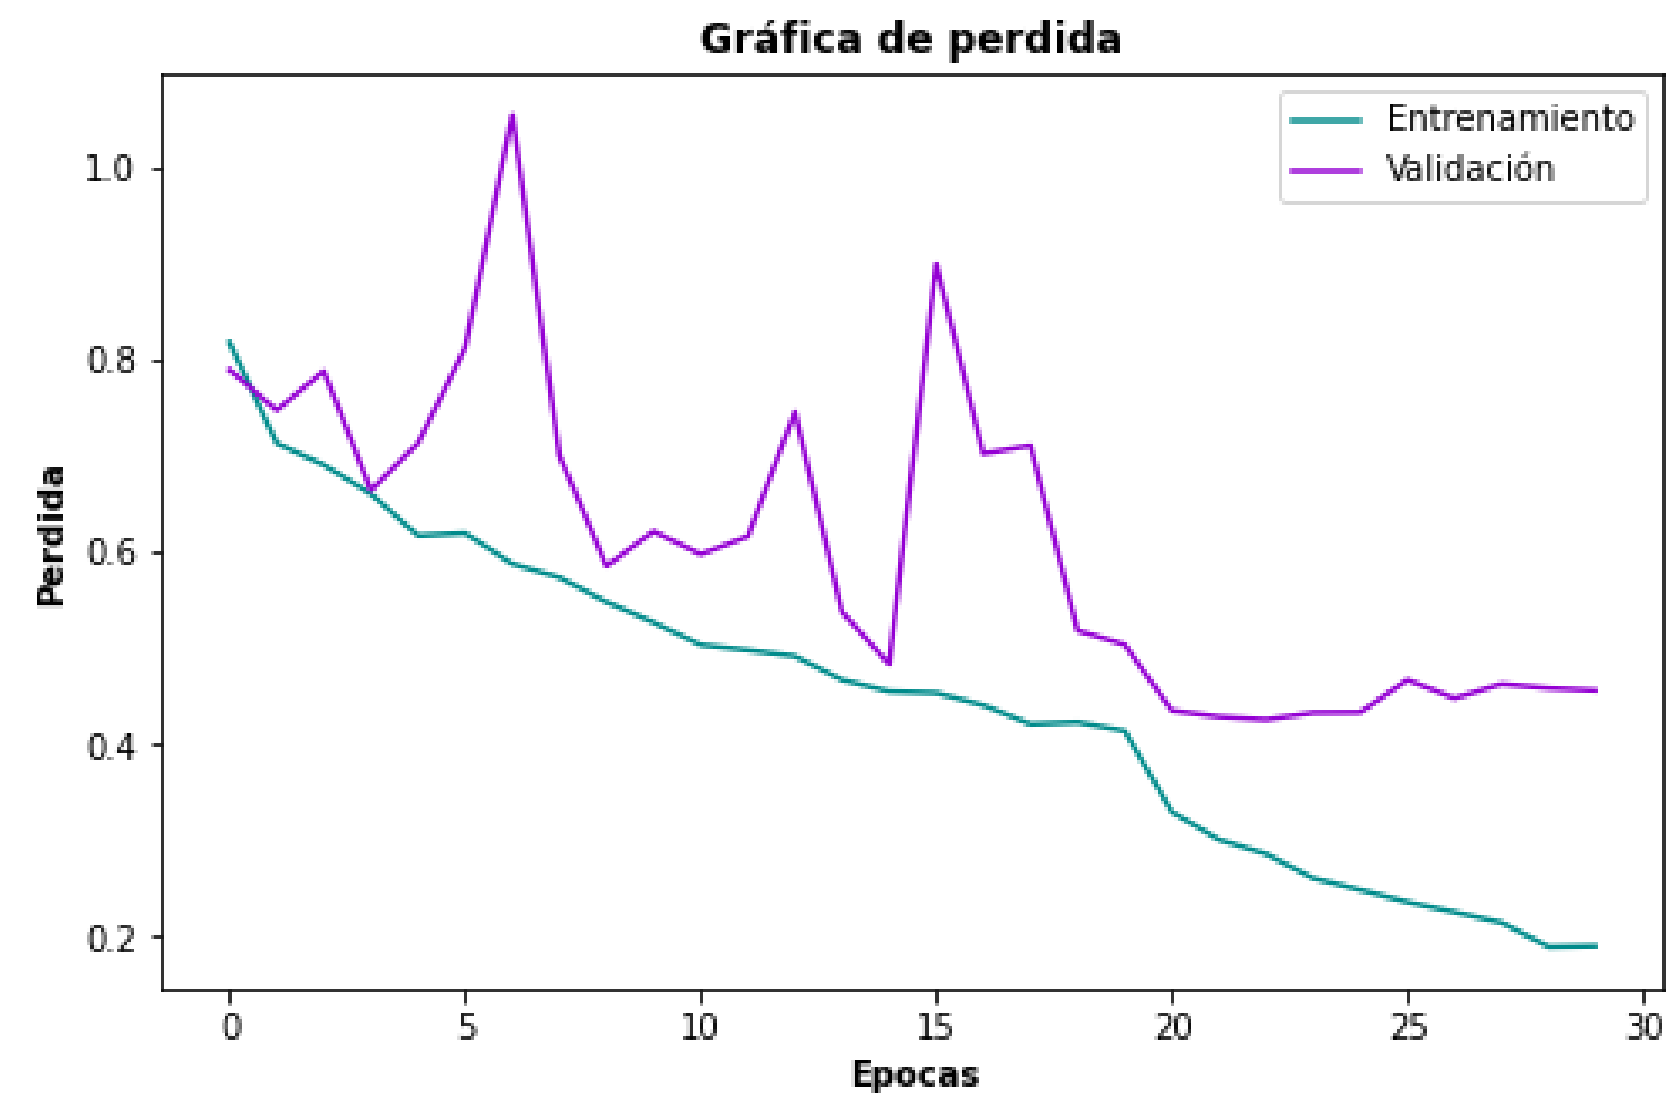
Entrenamiento: 93.32%
Validación: 80.13%

Gráfico de AUC



Entrenamiento: 99.16%
Validación: 94.73%


RESULTADOS



Entrenamiento: 0.1905

Validación: 0.4562


RESULTADOS



Métrica	Porcentaje
Exactitud	80.89%
Precisión	80.89%
Sensibilidad	80.89%
Puntaje F1	80.89%
AUC	85.67%

RESULTADOS

Gráfico de curva ROC




Reporte de clasificación:

	precision	recall	f1-score	support
Normal	0.94	0.92	0.93	242
Benigno	0.74	0.79	0.76	270
Cancer	0.77	0.74	0.75	273
accuracy			0.81	785
macro avg	0.82	0.81	0.81	785
weighted avg	0.81	0.81	0.81	785


PREDICCIONES

Predicciones del modelo (Verde: Correcto, Rojo: Incorrecto)


Real: Normal,
Predicho: Cancer,
Probabilidad: 61.26%




Real: Cancer,
Predicho: Benigno,
Probabilidad: 57.99%




Real: Benigno,
Predicho: Benigno,
Probabilidad: 99.25%




Real: Cancer,
Predicho: Cancer,
Probabilidad: 88.81%




Real: Normal,
Predicho: Normal,
Probabilidad: 99.6%




Real: Benigno,
Predicho: Cancer,
Probabilidad: 74.36%




Real: Normal,
Predicho: Normal,
Probabilidad: 90.06%




Real: Benigno,
Predicho: Cancer,
Probabilidad: 97.12%



Real: Cancer,
Predicho: Cancer,
Probabilidad: 98.02%




Real: Normal,
Predicho: Normal,
Probabilidad: 98.71%




Real: Cancer,
Predicho: Benigno,
Probabilidad: 49.49%




Real: Cancer,
Predicho: Cancer,
Probabilidad: 99.19%




Real: Benigno,
Predicho: Normal,
Probabilidad: 67.13%




Real: Cancer,
Predicho: Cancer,
Probabilidad: 92.56%



Real: Benigno,
Predicho: Benigno,
Probabilidad: 98.27%



Real: Normal,
Predicho: Normal,
Probabilidad: 97.19%



CONCLUSIONES

Los resultados obtenidos son buenos (>0.8), particularmente en la diferenciación de casos normales y las imágenes con un tumor ya sea benigno o maligno.

Se observa que la mayoría de los errores en el modelo están entre las clases de tumor benigno y maligno.

- Consideramos que, en parte, esto se debe a que el diagnóstico de cáncer en un tumor se basa en más características que no están presentes en la imagen.
- Por otra parte, un diagnóstico completo involucra otros estudios, opiniones y análisis adicionales.

Se muestra que los mejores resultados fueron obtenidos utilizando las imágenes de ambos ejes (CC y MLO).

- La CNN fue capaz de interpretar la información desde diferentes vistas sin recurrir a un aumento de datos.

MUCHAS GRACIAS :D

